

# Procesos Estocásticos

LibreIM

Doble Grado de Informática y Matemáticas  
Universidad de Granada

[libreim.github.io/apuntesDGIIM](https://libreim.github.io/apuntesDGIIM)



Este libro se distribuye bajo una licencia CC BY-NC-SA 4.0.

Eres libre de distribuir y adaptar el material siempre que reconozcas a los autores originales del documento, no lo utilices para fines comerciales y lo distribuyas bajo la misma licencia.

[creativecommons.org/licenses/by-nc-sa/4.0/](https://creativecommons.org/licenses/by-nc-sa/4.0/)

# Procesos Estocásticos

LibreIM

Doble Grado de Informática y Matemáticas  
Universidad de Granada

[libreim.github.io/apuntesDGIIM](https://libreim.github.io/apuntesDGIIM)

# Índice

<b>I. Teoría</b>	<b>5</b>
<b>1. Teoría general de procesos estocásticos</b>	<b>5</b>
1.1. Definición y propiedades generales . . . . .	5
1.1.1. Teoría de la medida . . . . .	5
1.1.2. Teoría de la probabilidad . . . . .	7
1.1.3. Definición de proceso estocástico . . . . .	9
1.1.4. Algunas características de procesos estocásticos . . . . .	10
1.2. Clasificación de los procesos estocásticos . . . . .	11
1.2.1. Clasificación atendiendo al $T$ y $E$ . . . . .	11
1.2.2. Clasificación atendiendo a la relación entre las variables del proceso . . . . .	12
1.3. Procesos estocásticos en tiempo discreto (PETD): Trayectorias y distribución . . . . .	13
1.3.1. Definición de PETD . . . . .	13
1.3.2. Trayectorias en un PETD . . . . .	13
1.3.3. Distribución de un PETD . . . . .	15
1.4. Procesos estocásticos en tiempo continuo (PETC): Trayectorias y distribución . . . . .	16
1.4.1. Definición de PETC . . . . .	16
1.4.2. Trayectorias . . . . .	16
1.4.3. Distribución de un PETC . . . . .	17
1.4.4. Equivalencia de procesos . . . . .	17
<b>II. Ejercicios</b>	<b>19</b>
<b>2. Tema 1</b>	<b>19</b>
2.1. Ejercicios mandados . . . . .	19
2.2. Ejercicios en clase . . . . .	23
2.3. Ejercicios PETC . . . . .	24

# Parte I.

## Teoría

### 1. Teoría general de procesos estocásticos

#### 1.1. Definición y propiedades generales

##### 1.1.1. Teoría de la medida

Veremos primero nociones básicas sobre la teoría de la medida.

**Definición 1.1 ( $\sigma$ -álgebra).** Una  $\sigma$ -álgebra  $\mathcal{A}$  sobre un conjunto  $\Omega$  es una familia de subconjuntos de  $\Omega$  ( $\mathcal{A} \subset \mathcal{P}(\Omega)$ ) que cumple:

- (i)  $\forall A \in \mathcal{A} \implies \bar{A} \in \mathcal{A}$
- (ii)  $\forall \{A_n\}_{n \in \mathbb{N}} \subset \mathcal{A} \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$

*Nota.*  $\mathcal{P}(\Omega)$  son las partes de  $\Omega$ , es decir, todos los subconjuntos posibles de  $\Omega$ .

La pertenencia del total, vacío y ser cerrado para intersecciones se deduce de las condiciones de la definición.

**Definición 1.2 (Espacio medible).** Un *espacio medible* es una tupla  $(\Omega, \mathcal{A})$  donde  $\Omega$  es un conjunto y  $\mathcal{A}$  es una  $\sigma$ -álgebra.

Para la teoría de la probabilidad tiene especial interés los espacios Borel, en los que toman valores las variables aleatorias.

**Ejemplo 1.1.**  $(\mathbb{R}, \mathcal{B})$ ,  $(\mathbb{R}^n, \mathcal{B}^n)$ .

**Definición 1.3 ( $\sigma$ -álgebra Borel).** La  $\sigma$ -álgebra de Borel es la generada por las semirrectas:

$$\mathcal{B}^n = \sigma(\mathcal{I}^n), \quad \mathcal{I}^n = \{(-\infty, x] : x \in \mathbb{R}^n\}$$

*Nota.*  $\sigma(D)$  es la  $\sigma$ -álgebra minimal generada por  $D$ .

**Definición 1.4 ( $\sigma$ -álgebra Borel restringida).** Sea un subconjunto  $E \subset \mathbb{R}$ , la  $\sigma$ -álgebra restringida a  $E$  es

$$\mathcal{B}_E = \{B \cap E : B \in \mathcal{B}\},$$

**Definición 1.5 (Espacio Borel restringido).** Sea un subconjunto  $E \subset \mathbb{R}$ , el espacio Borel restringido a  $E$  es  $(E, \mathcal{B}_E)$ .

Ahora veamos que pasa con las aplicaciones y funciones medibles.

**Definición 1.6 (Aplicación medible).** Sean dos espacios medibles  $(\Omega_1, \mathcal{A}_1)$ ,  $(\Omega_2, \mathcal{A}_2)$  una aplicación  $f : \Omega_1 \rightarrow \Omega_2$  se dice *aplicación medible*  $\iff \forall A \in \mathcal{A}_2, f^{-1}(A) \in \mathcal{A}_1 \iff f^{-1}(\mathcal{A}_2) \subset \mathcal{A}_1$ .

**Proposición 1.1 (Caracterización de aplicaciones medibles).** Una aplicación entre espacios medibles  $f : (\Omega_1, \mathcal{A}_1) \rightarrow (\Omega_2, \mathcal{A}_2)$  es aplicación medible  $\iff f^{-1}(D) \in \mathcal{A}_1$  siendo  $D \subset \mathcal{P}(\Omega_2)$  y  $\sigma(D) = \mathcal{A}_2$ .

**Proposición 1.2 (Composición de aplicaciones medibles).** Sean dos aplicaciones medibles  $f : (\Omega_1, \mathcal{A}_1) \rightarrow (\Omega_2, \mathcal{A}_2)$ ,  $g : (\Omega_2, \mathcal{A}_2) \rightarrow (\Omega_3, \mathcal{A}_3)$  entre tres espacios medibles. Entonces la composición  $g \circ f : (\Omega_1, \mathcal{A}_1) \rightarrow (\Omega_3, \mathcal{A}_3)$  es una aplicación medible.

*Demostración.*  $(g \circ f)^{-1}(\mathcal{A}_3) = f(g^{-1}(\mathcal{A}_3)) \in \mathcal{A}_1$  porque  $f$  es aplicación medible y  $g^{-1}(\mathcal{A}_3) \in \mathcal{A}_2$  ( $g$  es aplicación medible).  $\square$

**Definición 1.7 (Función medible).** Una *función medible* es una aplicación medible cuyo espacio de llegada es un espacio de Borel.

*Nota.* Si el espacio Borel es  $\mathbb{R}$  se denomina función medible *finita* (no toman valores en  $\pm\infty$ ).

**Proposición 1.3 (Caracterización de funciones medibles (1)).** Una función entre un espacio medible y espacio Borel  $f : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$  es función medible  $\iff f^{-1}(\mathcal{B}^n) \subset \mathcal{A}$ .

*Nota.* Para  $n = 1$  se dice función medible (*unidimensional*), para  $n > 1$  se denomina función medible *multidimensional*.

**Proposición 1.4 (Caracterización de funciones medibles (2)).** Una función entre un espacio medible y espacio Borel  $f : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$  es función medible  $\iff f^{-1}((-\infty, x]) \in \mathcal{A}, \forall x \in \mathbb{R}$ .

*Nota.*  $f^{-1}(B) = \{\omega \in \Omega : f(\omega) \in B\} = [f \in B]$ .  
 $f^{-1}((-\infty, x]) = \{\omega \in \Omega : f(\omega) \leq x\} = [f \leq x]$ .

**Definición 1.8 (Función medible Borel).** Una *función medible Borel* es una función medible cuyo espacio inicial también es espacio de Borel.

Ejemplos de funciones medibles:

## 1. Teoría general de procesos estocásticos

**Ejemplo 1.2.**  $\forall A \in \mathcal{A}$ , función indicadora  $1_A(\omega) = \begin{cases} 1, & \omega \in A \\ 0, & \omega \notin A \end{cases}$

**Ejemplo 1.3.** Función constante  $f(\omega) = c \in \mathbb{R}$ .

**Ejemplo 1.4.** Sean  $A_1, \dots, A_n \in \mathcal{A}$ ,  $x_1, \dots, x_n \in \mathbb{R}$ , función simple  $f(\omega) = \sum_{i=1}^n x_i 1_{A_i}(\omega)$ .

*Nota.* Cualquier función que parte del espacio medible  $(\Omega, \mathcal{P}(\Omega))$  es medible.

Veamos que la medibilidad de una función depende de la  $\sigma$ -álgebra del espacio de partida:

**Ejemplo 1.5.**  $f(\omega) = \omega$  es medible si  $f : (\mathbb{R}, \mathcal{B}) \rightarrow (\mathbb{R}, \mathcal{B})$ , pero no lo es si  $f : (\mathbb{R}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$  con  $\mathcal{A} = \{A \subset \mathbb{R} : A \text{ o } \bar{A} \text{ es numerable}\}$ .

Finalmente sobre medidas y espacios medibles:

**Definición 1.9 (Función  $\sigma$ -aditiva).** Una función de conjunto  $\sigma$ -aditiva definida sobre  $\mathcal{A}$  es una función  $\varphi : \mathcal{A} \rightarrow \mathbb{R}$  que cumple:

$$\forall \{A_n\}_{n \in \mathbb{N}}, A_i \cap A_j = \emptyset \forall i \neq j, \varphi\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \varphi(A_n)$$

**Definición 1.10 (Medida).** Una medida  $\mu$  es una función  $\sigma$ -aditiva no negativa, es decir que  $\forall A \in \mathcal{A} \mu(A) \geq 0$ .

**Definición 1.11 (Espacio de medida).** Un espacio de medida es una terna  $(\Omega, \mathcal{A}, \mu)$  formada por un espacio medible y una medida sobre dicho espacio.

**Definición 1.12 (Integral en espacio de medida).** Sea una función medible  $f : (\Omega, \mathcal{A}, \mu) \rightarrow (\mathbb{R}, \mathcal{B})$  entonces definimos la integral de  $f$  en este espacio como:

$$\int f d\mu := \int_{\Omega} f d\mu = \int_A f \mu = \int f \chi_A d\mu$$

### 1.1.2. Teoría de la probabilidad

La teoría de la probabilidad se desarrolla sobre un tipo especial de espacios de medida llamados *espacios de probabilidad*, a los elementos de la  $\sigma$ -álgebra se les llama *sucesos*; y a la medida *probabilidad*.

**Definición 1.13 (Probabilidad).** Una función  $P : \mathcal{A} \rightarrow \mathbb{R}$  se dice que es una *probabilidad* si cumple con los tres axiomas de Kolmogorov:

- (i)  $\forall A \in \mathcal{A}, P(A) \geq 0$  (no negativa).
- (ii)  $\forall \{A_n\}_{n \in \mathbb{N}} \subset \mathcal{A}$  disjuntos  $\implies P(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} P(A_n)$  ( $\sigma$ -aditividad).
- (iii)  $P(\Omega) = 1$  (normalización).

Luego una probabilidad es una medida normalizada.

**Definición 1.14 (Variable aleatoria).** Una *variable aleatoria* (v.a)  $X : \Omega \rightarrow \mathbb{R}$ ,  $\omega \mapsto X(\omega)$  es una función medible de un espacio de probabilidad en un espacio Borel; es decir:

$$X : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B}), \forall B \in \mathcal{B} \quad X^{-1}(B) \in \mathcal{A}$$

**Proposición 1.5 (Caracterización de variables aleatorias).**  $X$  es una variable aleatoria  $\iff \forall x \in \mathbb{R} \quad X^{-1}((-\infty, x]) = [X \leq x] \in \mathcal{A}$ .

**Definición 1.15 (Vector aleatorio).** Un *vector aleatorio* (v.a)  $X : \Omega \rightarrow \mathbb{R}^n$ ,  $\omega \mapsto X(\omega)$ , es una función medible multidimensional de un espacio de probabilidad en un espacio Borel (multidimensional).

La caracterización anterior es válida para vectores aleatorios, pero además veamos otra:

**Definición 1.16 (Caracterización de vectores aleatorios).**  $X$  es un vector aleatorio  $\iff \forall i = 1, \dots, n, X_i : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B})$  es una variable aleatoria.

*Demostración.* Se deja propuesto como ejercicio. □

**Definición 1.17 (Distribución de probabilidad).** Se llama *distribución de probabilidad* de una variable aleatoria a una función de probabilidad definida en el espacio de Borel:

$$P_X : \mathcal{B} \rightarrow \mathbb{R}$$

$$B \mapsto P_X(B) = P(X^{-1}(B)) = P[X \in B]$$

*Demostración.* Hecho en 2.2 □

El teorema de correspondencia nos dice que la función de conjunto  $P_X$  puede ponerse en correspondencia biunívoca con la función de distribución  $F_X$ .



**Definición 1.18 (Función de distribución).** La *función de distribución* es la función de puntos:

$$F : \mathbb{R} \rightarrow \mathbb{R}$$

$$x \mapsto F_X(x) = P_X((-\infty, x]) = P[X \leq x]$$

El teorema de correspondencia nos permite también establecer una correspondencia biunívoca entre la función de distribución y la función característica  $\varphi_X$ .

**Definición 1.19 (Función característica).** La *función característica* se define como  $\varphi_X(t) = E[e^{itX}]$ ,  $\forall t \in \mathbb{R}$ .

La correspondencia entre estos tres tipos de funciones se llama *ley de la variable aleatoria* y existe también la versión análoga para vectores aleatorios.

**Definición 1.20 (Función masa de probabilidad).** Sea  $X$  una v.a discreta, se define la *función masa de probabilidad* como  $f(x) = P[X = x]$ ,  $\forall x \in \mathcal{B}_X$ .

Su función característica asociada es  $\varphi_X(t) = \sum_{x \in \mathcal{B}_X} e^{itx} P[X = x]$ ,  $\forall t \in \mathbb{R}$ .

**Definición 1.21 (Función de densidad).** Sea  $X$  una v.a continua, la *función de densidad* es la que cumple  $F_X(x) = \int_{-\infty}^x f(y)dy$ ,  $\forall x \in \mathbb{R}$

Su función característica asociada es  $\varphi_X(t) = \int e^{it} f(x)dx$ ,  $\forall t \in \mathbb{R}$ .

### 1.1.3. Definición de proceso estocástico

Veamos que es un proceso estocástico y ciertas definiciones sobre él:

**Definición 1.22 (Proceso estocástico).** Un *proceso estocástico* (p.e) es una familia de variables aleatorias  $\{X_t\}_{t \in T}$ , donde  $T$  un conjunto ordenado arbitrario y cada v.a está definida sobre un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ .

*Nota.* En algunas ocasiones llamaremos al proceso estocástico como proceso.

**Definición 1.23 (Espacio paramétrico).** Se llama *espacio paramétrico* al conjunto ordenado arbitrario  $T$ : en el caso discreto se suele tomar  $\mathbb{N} \cup \{0\}$ , y en el continuo  $[0, +\infty)$ .

**Definición 1.24 (Proceso estocástico real).** Un p.e se dice que es *real* si  $\forall t \in T$ ,  $X_t : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B})$ .

*Nota.* En este curso son los procesos estocásticos que consideraremos, junto tam-

bien a los p.e multidimensionales (espacio Borel de llegada multidimensional).

**Definición 1.25 (Espacio de estados).** Se llama *espacio de estados* al espacio Borel donde toman valores las v.a. En general, sea  $E \subset \mathbb{R}$  con la  $\sigma$ -álgebra Borel restringida  $\mathcal{B}_E$ , el espacio de estados es  $(E, \mathcal{B}_E)$ ,

*Nota.* Si no se especifica uno diferente, se considera  $(\mathbb{R}, \mathcal{B})$ .

**Definición 1.26 (Trayectoria).**  $\forall \omega \in \Omega$  fijo, definimos la *trayectoria* asociada a  $\omega$  como

$$\begin{aligned} X(\omega) : T &\rightarrow \mathbb{R} \\ t &\mapsto X_t(\omega). \end{aligned}$$

**Ejemplo 1.6.** Proceso de recuento:

- $X_t \equiv$  número de veces que ocurre un suceso en el intervalo  $[0, t]$ .
- $T = [0, +\infty]$ .
- $E = \mathbb{N} \cup \{0\}$ .
- $s \leq t \in T \implies X_s \leq X_t$  trayectorias crecientes a saltos.

**Ejemplo 1.7.** Recorrido aleatorio:

- $X_n \equiv$  posición de la partícula en el instante  $n$ .
- $T = \mathbb{N} \cup \{0\}$ .
- $E = \mathbb{Z}$ .

#### 1.1.4. Algunas características de procesos estocásticos

Sea  $\{X_t\}_{t \in T}$  p.e definido sobre el espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ , suponemos que existen las esperanzas de las siguientes definiciones:

**Definición 1.27 (Función media).** La *función media* es una función que asigna a cada  $t$  la esperanza de la variable aleatoria asociada a  $t$ , es decir:

$$\begin{aligned} \mu : T &\rightarrow \mathbb{R} \\ t &\mapsto \mu(t) = \mu_t = E[X_t] \end{aligned}$$

*Nota.* Para que la definición sea válida se debe tener  $\forall t \in T, E[|X_t|] < \infty$ .

**Definición 1.28 (Proceso centrado).** Un p.e se dice *centrado* si se cumple  $\mu(t) = 0, \forall t \in T$ .

**Definición 1.29 (Momentos no centrados de orden  $k$ ).** El *momento no centrado*

## 1. Teoría general de procesos estocásticos

de orden  $k$  se define como:

$$\begin{aligned}\mu_k : T &\rightarrow \mathbb{R} \\ t &\mapsto \mu_k(t) = E[X_t^k]\end{aligned}$$

**Definición 1.30 (Momentos centrados de orden  $k$ ).** El momento centrado de orden  $k$  se define como:

$$\begin{aligned}m_k : T &\rightarrow \mathbb{R} \\ t &\mapsto m_k(t) = E[(X_t - \mu_t)^k]\end{aligned}$$

**Definición 1.31 (Función varianza).** La función varianza es  $\sigma_t^2 = m_2(t)$

**Definición 1.32 (Función correlación).** La función correlación se define como:

$$\begin{aligned}R : T \times T &\rightarrow \mathbb{R} \\ (s, t) &\mapsto R(s, t) = E[X_s X_t]\end{aligned}$$

**Definición 1.33 (Función covarianza).** La función covarianza se define como:

$$\begin{aligned}C : T \times T &\rightarrow \mathbb{R} \\ (s, t) &\mapsto C(s, t) = E[(X_s - \mu_s)(X_t - \mu_t)] = R(s, t) - \mu_s \mu_t\end{aligned}$$

*Nota.* Consideraciones:

- $C(t, t) = \sigma_t^2$ .
- Si el proceso es centrado entonces la correlación y la covarianza coinciden.

**Definición 1.34 (Procesos de segundo orden).** Un p.e  $\{X_t\}_{t \in T}$  se dice de *segundo orden* si  $\forall t \in T, E[X_t^2] < \infty$  (las v.a son cuadrado integrables).

## 1.2. Clasificación de los procesos estocásticos

### 1.2.1. Clasificación atendiendo al $T$ y $E$

Sea  $\{X_t\}_{t \in T}$  p.e definido sobre el espacio de probabilidad  $(\Omega, \mathcal{A}, P)$  con espacio de estados  $(E, \mathcal{B}_E)$ .

**Definición 1.35 (Procesos en tiempo discreto).** Un p.e es en *tiempo discreto* si  $T$  es discreto, es decir,  $T \subset \mathbb{Z}$ .

*Nota:* para TD usaremos  $T = \mathbb{N} \cup \{0\}$  y notamos  $\{X_n\}_{n \in \mathbb{N}^*}$  (sucesiones de v.a).

**Definición 1.36 (Procesos en tiempo continuo).** Un p.e es en *tiempo continuo* si  $T$  es continuo, es decir,  $T \subset \mathbb{R}$ .

Nota: para TC usaremos  $T = [0, +\infty]$  y notamos  $\{X_t\}_{t \in \mathbb{R}^+}$ .

**Definición 1.37 (Procesos discretos).** Un p.e es *discreto* si  $E$  es discreto, es decir,  $E$  es conjunto numerable.

Nota: también se les denota como Cadenas.

**Definición 1.38 (Procesos continuos).** Un p.e es en *continuo* si  $E$  es continuo, es decir  $E$  es conjunto no numerable.

Veamos unos ejemplos:

**Ejemplo 1.8. PDTD.** Resultado de lanzar un dado en el  $n$ -ésimo lanzamiento.  
 $T = \mathbb{N}$ ,  $E = \{1, 2, 3, 4, 5, 6\}$ .

**Ejemplo 1.9. PCTD.** Cantidad de lluvia en el  $n$ -ésimo día.  
 $T = \mathbb{N}$ ,  $E = \mathbb{R}_0^+$ .

**Ejemplo 1.10. PDTC.** Cantidad de clientes en el instante  $t$ .  
 $T = [0, +\infty)$ ,  $E = \mathbb{N} \cup \{0\}$ .

**Ejemplo 1.11. PCTC.** Cantidad de lluvia en el instante  $t$ .  
 $T = [0, +\infty)$ ,  $E = \mathbb{R}_0^+$ .

## 1.2.2. Clasificación atendiendo a la relación entre las variables del proceso

Sea  $\{X_t\}_{t \in T}$  p.e definido sobre el espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ .

**Definición 1.39 (Proceso independiente).** Un p.e es *independiente* si  $\forall n > 1, t_1, \dots, t_n \in T$   
 $X_{t_1}, \dots, X_{t_n}$  son v.a independientes.

**Definición 1.40 (Proceso con incrementos independientes).** Un p.e tiene *incrementos independientes* si  $\forall n > 1, \forall t_1 < \dots < t_n \in T$

$X_{t_1}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$  son v.a independientes.

**Definición 1.41 (Proceso con incrementos estacionarios).** Un p.e tiene *incrementos estacionarios* si  $\forall s < t \in T, \forall h$

$$(X_t - X_s) \sim (X_{t+h} - X_{s+h}).$$

Nota.  $X \sim Y$  indica que  $X$  sigue la misma distribución que  $Y$ .

**Definición 1.42 (Proceso estacionario).** Un p.e es *estrictamente estacionario* si  $\forall n, \forall t_1 < \dots < t_n \in T, \forall h$

$$(X_{t_1}, \dots, X_{t_n}) \sim (X_{t_1+h}, \dots, X_{t_n+h}).$$

**Definición 1.43 (Proceso débilmente estacionario).** Un p.e de 2º orden es *débilmente estacionario* si cumple

- (i) Su función media es constante
- (ii)  $C(s, t) = C(s + h, t + h) = C(0, t - s), \forall s, t \in T.$

*Nota.* Todos procesos de 2º orden estrictamente estacionarios son débilmente estacionarios.

**Definición 1.44 (Martingala (tiempo discreto)).** Un p.e es una *martingala* si  $\forall n \in \mathbb{N}$

$$E[X_{n+1} | X_1, \dots, X_n] = X_n \text{ c.s}$$

**Definición 1.45 (Procesos de Markov).** Un p.e es un *Proceso de Markov* si  $\forall s < t \in T, \forall B \in \mathcal{B}$

$$P[X_t \in B | X_n, n \leq s] = P[X_t \in B | X_s] \text{ c.s}$$

### 1.3. Procesos estocásticos en tiempo discreto (PETD): Trayectorias y distribución

#### 1.3.1. Definición de PETD

Consideramos el espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ , espacio paramétrico discreto  $T \equiv \mathbb{N}$ , y espacios de estados  $(\mathbb{R}, \mathcal{B})$ .

**Definición 1.46 (Proceso estocástico en tiempo discreto).** Un p.e en tiempo discreto (PETD) es una sucesión  $\{X_n\}_{n \in \mathbb{N}}$  de v.a definidas en  $(\Omega, \mathcal{A}, P)$  t.q  $\forall n \in \mathbb{N}$ :

$$X^{-1}(B) \in \mathcal{A}, \forall B \in \mathcal{B} \iff [X \leq x] \in \mathcal{A}, \forall x \in \mathbb{R}$$

#### 1.3.2. Trayectorias en un PETD

**Definición 1.47 (Trayectoria (PETD)).** Sea un PETD  $\{X_n\}_{n \in \mathbb{N}}$ , fijando  $\omega \in \Omega$

definimos la *trayectoria* de  $\omega$  como:

$$\begin{aligned} X(\omega) : \mathbb{N} &\rightarrow \mathbb{R} \\ n &\mapsto X_n(\omega) \end{aligned}$$

Vemos que  $\{X_n(\omega)\}_{n \in \mathbb{N}}$  es una sucesión de números reales. Así, definiendo  $\mathbb{R}^{\mathbb{N}} = \{\{x_n\}_{n \in \mathbb{N}} : x_n \in \mathbb{R}, n \in \mathbb{N}\}$ , tenemos que  $\{X_n(\omega)\}_{n \in \mathbb{N}} \in \mathbb{R}^{\mathbb{N}}$ .

**Definición 1.48 (Trayectoria asociada (PETD)).** Sea un PETD  $\{X_n\}_{n \in \mathbb{N}}$ , definimos la *trayectoria asociada* como la función que asigna a cada elemento su trayectoria:

$$\begin{aligned} \chi : (\Omega, \mathcal{A}) &\rightarrow (\mathbb{R}^{\mathbb{N}}, \mathcal{B}^{\mathbb{N}}) \\ \omega &\mapsto X(\omega) = \{X_n(\omega)\}_{n \in \mathbb{N}} \end{aligned}$$

Necesitamos saber como es el espacio Borel  $(\mathbb{R}^{\mathbb{N}}, \mathcal{B}^{\mathbb{N}})$ , para ello veamos unas definiciones:

**Definición 1.49 (Rectángulo).** Dados  $B_1, \dots, B_n \subset \mathbb{R}$  llamamos un *rectángulo* de lados  $B_1, \dots, B_n$  a  $\{\{a_n\}_{n \in \mathbb{N}} \in \mathbb{R}^{\mathbb{N}} : x_1 \in B_1, \dots, x_n \in B_n\} = B_1 \times B_2 \times \dots \times B_n \times \mathbb{R} \times \dots$ .

**Definición 1.50 (Rectángulo medible).** Un *rectángulo medible* es un rectángulo donde  $B_1, \dots, B_n \in \mathcal{B}$ .

**Definición 1.51 (Clase de rectángulos medibles).** Denotamos por  $\mathcal{C}^{\mathbb{N}}$  la *clase de rectángulos medibles*.

**Definición 1.52 (Semi-álgebra).** Una *semi-álgebra* sobre  $\Omega$  es un conjunto  $\mathcal{C} \in \mathcal{P}(\Omega)$  verificando:

- (i)  $\Omega \in \mathcal{C}$
- (ii)  $\forall A, B \in \mathcal{C} \implies A \cap B \in \mathcal{C}$
- (iii)  $\forall A \in \mathcal{C} \implies \bar{A}$  es unión finita disjunta de elementos de  $\mathcal{C}$ .

No hay ningún método constructivo para hallar la  $\sigma$ -álgebra minimal asociada a un conjunto, pero si tenemos una semi-álgebra solo nos falta comprobar que estén los complementarios, o lo que es lo mismo, que las uniones finitas disjuntas estén.

**Definición 1.53 ( $\sigma$ -álgebra de rectángulos medibles).** El  *$\sigma$ -álgebra de rectángulos medibles* es el  $\sigma$ -álgebra minimal generada por los rectángulos medibles, es decir,  $\sigma(\mathcal{C}^{\mathbb{N}})$ .

**Definición 1.54 ( $\sigma$ -álgebra Borel sobre  $\mathbb{R}^{\mathbb{N}}$ ).** La  $\sigma$ -álgebra Borel sobre  $\mathbb{R}^{\mathbb{N}}$  es  $\mathcal{B}^{\mathbb{N}}$  que es la  $\sigma$ -álgebra sobre la clase  $\mathcal{C}^{\mathbb{N}}$ , es decir  $\mathcal{B}^{\mathbb{N}} \equiv \sigma(\mathcal{C}^{\mathbb{N}})$ .

**Teorema 1.1 (Teorema de medibilidad (Caracterización de PETD)).** Sea  $(\Omega, \mathcal{A}, P)$  espacio de probabilidad,  $T \equiv \mathbb{N}$ , consideramos  $\forall n \in \mathbb{N}, X_n : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$  y

$$\begin{aligned}\chi : \Omega &\rightarrow \mathbb{R}^{\mathbb{N}} \\ \omega &\mapsto \{X_n(\omega)\}_{n \in \mathbb{N}}\end{aligned}$$

Entonces,  $\chi : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}^{\mathbb{N}}, \mathcal{B}^{\mathbb{N}})$  es función medible  $\iff \forall n \in \mathbb{N}, X_n$  es v.a  $\iff \{X_n\}_{n \in \mathbb{N}}$  es PETD.

### 1.3.3. Distribución de un PETD

**Definición 1.55 (Distribución de un PETD).** Sea  $\{X_n\}_{n \in \mathbb{N}}$  un PETD definido sobre  $(\Omega, \mathcal{A}, P)$ , la *distribución del PETD* es una probabilidad definida:

$$\begin{aligned}P_\chi : \mathcal{B}^{\mathbb{N}} &\rightarrow [0, 1] \\ B &\mapsto P(\chi^{-1}(B)) = P[\chi \in B]\end{aligned}$$

$P_\chi$  está bien definida porque  $\chi^{-1}(B) \in \mathcal{A}$  al ser  $\chi$  función medible (T. medibilidad), y es una probabilidad (se puede comprobar fácilmente).

Por los Teoremas de extensión podemos conocer la medida en el  $\sigma$ -álgebra conociendo solo la medida finita en el semi-álgebra, ya que se extiende de forma única a una medida sobre el álgebra minimal sobre la semi-álgebra (sumatoria de los conjuntos); que a su vez se extiende de forma única sobre la  $\sigma$ -álgebra minimal sobre la álgebra (que desconocemos).

**Teorema 1.2 (Teorema de consistencia de Kolmogorov).** Sea  $\forall n \in \mathbb{N}, P_n$  medida en  $(\mathbb{R}^n, \mathcal{B}^n)$  verificando la *propiedad de consistencia*:

$$P_n(B_1 \times \dots \times B_n) = P_{n+1}(B_1 \times \dots \times B_n \times \mathbb{R}), \forall B_1, \dots, B_n \in \mathcal{B}$$

Entonces:

$$\exists! \hat{P} : \mathcal{B}^{\mathbb{N}} \rightarrow [0, 1], \hat{P}(\{(x_n)_{n \in \mathbb{N}} : x_1 \in B_1, \dots, x_n \in B_n\}) = P_n(B_1 \times \dots \times B_n)$$

**Corolario 1.1.** La distribución de probabilidad  $P_\chi$  está determinada por las distribuciones finito dimensionales,  $\forall n \in \mathbb{N}, \text{dist}(X_1, \dots, X_n) = P_n = P_{(X_1, \dots, X_n)}(B_1 \times \dots \times B_n) = P[X_1 \in B_1, \dots, X_n \in B_n]$ .

*Demostración.* Veamos que  $\{P_{(X_1, \dots, X_n)}\}_{n \in \mathbb{N}}$  es sucesión de distribuciones de probabilidad que verifican la propiedad de consistencia.

Se verifica ya que  $P_{(X_1, \dots, X_n)}(B_1 \times \dots \times B_n) = P[X_1 \in B_1, \dots, X_n \in B_n] = P[X_1 \in$

$$B_1, \dots, X_n \in B_n, X_{n+1} \in \mathbb{R}] = P_{(X_1, \dots, X_n, X_{n+1})}(B_1 \times \dots \times B_n \times \mathbb{R}).$$

Ahora veamos que  $P_\chi \equiv \hat{P}$ .

$$\text{Sea } S \in \mathcal{C}^\mathbb{N}, P_\chi(S) = P(\chi^{-1}(S)) = P\{\omega \in \Omega : \chi(\omega) \in S\} = P\{\omega \in \Omega : \{X_n(\omega)\}_{n \in \mathbb{N}} \in S\} = P[X_1 \in B_1, \dots, X_n \in B_n] = P_{(X_1, \dots, X_n)}(B_1 \times \dots \times B_n) = \hat{P}(S) \quad \square$$

## 1.4. Procesos estocásticos en tiempo continuo (PETC): Trayectorias y distribución

### 1.4.1. Definición de PETC

**Definición 1.56 (Proceso estocástico en tiempo continuo).** Sea espacio de probabilidad  $(\Omega, \mathcal{A}, P)$  y un intervalo  $T \subseteq \mathbb{R}$ , un *proceso estocástico en tiempo continuo* (PETC)  $\{X_t\}_{t \in T}$  es una familia de v.a definidas sobre  $(\Omega, \mathcal{A}, P)$ , es decir:

$$\forall t \in T, X_t : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B}) \text{ es medible} \iff X_t^{-1}(B) \in \mathcal{A}, \forall B \in \mathcal{B} \iff X_t^{-1}((-\infty, x]) \in \mathcal{A}, \forall x \in \mathbb{R} \quad (1)$$

### 1.4.2. Trayectorias

**Definición 1.57 (Trayectoria(PETC)).** Sea  $\omega \in \Omega$ , definimos la *trayectoria* de  $\omega$  como

$$\begin{aligned} X(\omega) : T &\rightarrow \mathbb{R} \\ t &\mapsto X_t(\omega) \end{aligned}$$

Tenemos que ver ahora si la función que asocia elementos a sus trayectorias es medible:

$$\begin{aligned} \chi : \Omega &\rightarrow \mathbb{R}^T \\ \omega &\mapsto \{X_t(\omega)\}_{t \in T} \end{aligned}$$

**Definición 1.58 ( $\mathbb{R}^T$ ).** Definimos  $\mathbb{R}^T$  como  $\mathbb{R}^T = \{f : T \rightarrow \mathbb{R}\}$  (trayectorias).

Necesitamos un  $\sigma$ -álgebra con  $\mathbb{R}^T$ , veamos como la definimos:

**Definición 1.59 (Rectángulo en  $\mathbb{R}^T$ ).** Definimos el *rectángulo de lados*  $B_1, \dots, B_n$  con  $B_i \subseteq \mathbb{R}$  como  $R = \{f \in \mathbb{R}^T : f(t_1) \in B_1, \dots, f(t_n) \in B_n, \forall t_1, \dots, t_n \in T\}$ .

**Definición 1.60 ( $\sigma$ -álgebra Borel  $\mathcal{B}^T$ ).** Definimos la  $\sigma$ -álgebra Borel  $\mathcal{B}^T$  como el  $\sigma$ -álgebra minimal sobre el álgebra de rectángulo medibles, es decir,  $\mathcal{B}^T = \sigma(\text{Álg. de rect. medibles}) = \sigma(\mathcal{C}^T)$ .



**Definición 1.61 (Teorema de medibilidad(PETC)).** Sea un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ , un intervalo  $T \subseteq \mathbb{R}$ ,  $\forall t \in T$ , las funciones  $X_t : \Omega \rightarrow \mathbb{R}$ , y la función

$$\begin{aligned}\chi : \Omega &\rightarrow \mathbb{R}^T \\ \omega &\mapsto \{X_t(\omega)\}_{t \in T}\end{aligned}$$

. Entonces  $\chi : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}^T, \mathcal{B}^T)$  es medible  $\iff \forall t \in T, X_t : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B})$  es v.a  $\iff \{X_t\}_{t \in T}$  es un PETC.

#### 1.4.3. Distribución de un PETC

**Definición 1.62 (Distribución de un PETD).** La distribución de un PETD  $\{X_t\}_{t \in T}$  definido sobre el espacio de probabilidad  $(\Omega, \mathcal{A}, P)$  es una probabilidad definida como:

$$\begin{aligned}P_\chi : \mathcal{B}^T &\rightarrow [0, 1] \\ B &\mapsto P_\chi(B) = P(\chi^{-1}(B)) = P[\chi \in B]\end{aligned}$$

Está bien definida por ser  $\chi$  medible, y es una probabilidad (comprobable fácilmente).

#### 1.4.4. Equivalencia de procesos

Sea  $(\Omega, \mathcal{A}, P)$  el espacio de probabilidad, espacio paramétrico  $T \subseteq \mathbb{R}$  y  $\{X_t\}_{t \in T}$ ,  $\{Y_t\}_{t \in T}$  dos PETC con distribuciones  $P_\chi$  y  $P_y$  respectivamente.

**Definición 1.63 (Equivalencia en sentido amplio de procesos).** Dos PETC  $\{X_t\}_{t \in T}$  y  $\{Y_t\}_{t \in T}$  son *equivalentes en sentido amplio* si y solo si tienen la misma distribución, es decir,  $P_\chi \equiv P_y$  o lo que es lo mismo:

$$P_\chi(B) = P_y(B), \forall B \in \mathcal{B}^T$$

Para esta definición no es necesario que los dos procesos estén definidos en el mismo espacio de probabilidad.

**Proposición 1.6 (Caracterización de equivalencia).** Dos PETC  $\{X_t\}_{t \in T}$  y  $\{Y_t\}_{t \in T}$  son *equivalentes en sentido amplio* si y solo si sus distribuciones finito-dimensional son iguales, es decir:

$$\begin{aligned}P[X_{t_1} \in B_1, \dots, X_{t_n} \in B_n] &= P[Y_{t_1} \in B_1, \dots, Y_{t_n} \in B_n], \\ \forall n \in \mathbb{N}, \forall t_1, \dots, t_n \in T, \forall B_1, \dots, B_n \in \mathcal{B}\end{aligned}$$

**Definición 1.64 (Equivalencia de procesos).** Dos PETC  $\{X_t\}_{t \in T}$  y  $\{Y_t\}_{t \in T}$  son *equivalente* si y solo si todas sus v.a son iguales casi seguramente, es decir:

$$P[X_t = Y_t] = 1, \forall t \in T$$

**Definición 1.65 (Indistinguibilidad de procesos).** Dos PETC  $\{X_t\}_{t \in T}$  y  $\{Y_t\}_{t \in T}$  son *indistinguibles* si y solo si

$$[X_t - Y_t] \in \mathcal{A}, P[X_t = Y_t, t \in T] = 1$$

**Proposición 1.7.** Sean las siguientes definiciones:

- (i) Equivalentes en sentido amplio
- (ii) Equivalentes
- (iii) Indistinguibles

Entonces  $3 \Rightarrow 2 \Rightarrow 1$ , pero  $1 \not\Rightarrow 2 \not\Rightarrow 3$ .

**Demostración.**  $\boxed{3 \Rightarrow 2}$

$$1 = P[X_t = Y_t, t \in T] \leq P[X_t = Y_t] \leq 1 \implies P[X_t = Y_t] = 1, \forall t \in T.$$

$\boxed{2 \Rightarrow 1}$

Denotamos  $A_j = [X_{t_j} = Y_{t_j}]$ , tenemos que

$$1 \geq P[X_{t_1} = Y_{t_1}, \dots, X_{t_n} = Y_{t_n}] = P\left[\bigcap_{j=1}^n A_j\right] = 1 - P\left(\bigcup_{j=1}^n \overline{A_j}\right) \geq 1 - \sum_{j=1}^n P(\overline{A_j}) = 1$$

Luego tenemos que  $P[X_t = Y_t] = 1 \implies P[X_{t_1} = Y_{t_1}, \dots, X_{t_n} = Y_{t_n}] = 1$ .

$$P[X_{t_1} \in B_1, \dots, X_{t_n} \in B_n] = P$$

$\boxed{2 \not\Rightarrow 3}$

Sea el espacio de probabilidad  $([0, 1], \mathcal{B}_{[0,1]}, P \equiv \text{Lebesgue})$ , con  $T = [0, 1]$ ,

consideramos las v.a  $\forall t \in T, \forall \omega \in \Omega, X_t(\omega) = 0$  y  $Y_t(\omega) = \begin{cases} 0, & \omega \neq t \\ 1, & \omega = t \end{cases}$

Entonces  $P[X_t \neq Y_t] = P\{\omega \in \Omega : X_t(\omega) \neq Y_t(\omega)\} = P\{w = t\} = 0$ , por lo que los PETC son equivalentes, pero  $P\{\omega \in \Omega : X_t(w) = Y_t(w), t \in T\} = P(\emptyset) = 0$ , luego no son indistinguibles.

$\boxed{1 \not\Rightarrow 2}$

$$P[X_t = Y_t] = P[X_t = 0, Y_t = 0] + P[X_t = 1, Y_t = 1] = P[X_t = 0]P[X_t = 0] + P[X_t = 1]P[Y_t = 1] = \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{2}, \text{ luego no son equivalentes. } \square$$

**Nota.** Para PETD se define exactamente igual y todo es igual, excepto para la indistinguibilidad que el conjunto pertenezca a la  $\sigma$ -álgebra ya se cumple por ser un conjunto numerable.

# Parte II.

## Ejercicios

### 2. Tema 1

#### 2.1. Ejercicios mandados

**Ejercicio 2.1.** Definir la distribución de probabilidad, función de distribución y función característica de una variable aleatoria y expresar dichas funciones en términos de la función masa de probabilidad o la función de densidad, según que la variable sea de tipo discreto o continuo, respectivamente.

*Solución.* La *distribución de probabilidad* de una variable aleatoria es una función de probabilidad definida en el espacio de Borel:

$$P_X : \mathcal{B} \rightarrow [0, 1]$$
$$B \mapsto P_X(B) = P(X^{-1}(B)) = P[X \in B]$$

La *función de distribución* es la función de puntos definida como:

$$F : \mathbb{R} \rightarrow [0, 1]$$
$$x \mapsto F_X(x) = P_X((-\infty, x]) = P[X \leq x]$$

La *función característica* es la función definida como

$$\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$$
$$t \mapsto \varphi_X(t) = E[e^{itX}]$$

- Caso discreto:

$$\forall B \in \mathcal{B}, P_X(B) = \sum_{x \in B \cap E_X} P[X = x] = \sum_{x \in B \cap E_X} f(x)$$

$$\forall x \in \mathbb{R}, F_X(x) = P_X((-\infty, x]) = \sum_{x \in E_X, x \leq y} P[X = x] = \sum_{x \in E_X, x \leq y} f(x)$$

$$\forall t \in \mathbb{R}, \varphi_X(t) = E[e^{itX}] = \sum_{x \in E_X} e^{itx} P[X = x] = \sum_{x \in E_X} e^{itx} f(x)$$

- Caso continuo:

$$\forall B \in \mathcal{B}, P_X(B) = \int_B f(x) dx$$

## 2. Tema 1

$$\forall x \in \mathbb{R}, F_X(x) = P_X((-\infty, x]) = P[X \in (-\infty, x]] = P[X \leq x] = \int_{-\infty}^x f(y)dy$$

$$\forall t \in \mathbb{R}, \varphi_X(t) = E[e^{itX}] = \int_{\mathbb{R}} e^{itx} f(x)dx$$

Donde  $f(x)$  representa la función masa de probabilidad en el caso discreto, y la función densidad en el caso continuo.

**Ejercicio 2.2.** Demostrar que la distribución de probabilidad de una variable aleatoria es una medida de probabilidad definida sobre la  $\sigma$ -álgebra de Borel.

*Solución.* Veamos si

$$\begin{aligned} P_X : \mathcal{B} &\rightarrow \mathbb{R} \\ B &\mapsto P_X(B) = P(X^{-1}(B)) = P[X \in B] \end{aligned}$$

cumple con los tres Axiomas de Kolmogorov, usando que  $P$  es una probabilidad:

- (i)  $P_X(B) = P[X \in B] \geq 0, \forall B \in \mathcal{B}$ .
- (ii)  $\forall \{B_n\}_{n \in \mathbb{N}} \subset \mathcal{B}$  disjuntos

$$P_X\left(\bigcup_{n=1}^{\infty} B_n\right) = P\left[X \in \bigcup_{n=1}^{\infty} B_n\right] = P\left[\bigcup_{n=1}^{\infty} (X \in B_n)\right] = \sum_{n=1}^{\infty} P[X \in B_n] = \sum_{n=1}^{\infty} P_X(B_n)$$

- (iii)  $P_X(\mathbb{R}) = P[X^{-1}(\mathbb{R})] = P[\Omega] = 1$

**Ejercicio 2.3.** Demostrar la caracterización de vectores aleatorios mediante variables aleatorias.

*Solución.* Sea  $X = (X_1, \dots, X_n) : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$ , entonces  $X$  es vector aleatorio  $\iff X_1, \dots, X_n$  son variables aleatorias.

$$\begin{aligned} X \text{ v.a.} &\iff \forall x = (x_1, \dots, x_n) \in \mathbb{R}^n, X^{-1}((-\infty, x]) = [X \leq x] = \\ &= [X_1 \leq x_1, \dots, X_n \leq x_n] = \bigcap_{i=1}^n [X_i \leq x_i] \subset \mathcal{A} \iff \forall i \in \{1, \dots, n\}, \forall x_i \in \mathbb{R} \\ &\mathcal{A} \supset [X_i \leq x_i] = X^{-1}((-\infty, x_i]) \iff X_1, \dots, X_n \text{ v.a.} \end{aligned}$$

Vemos la penúltima implicación tomando  $x_j = \infty \forall j \neq i$  en  $\bigcap_{i=1}^n [X_i \leq x_i] \subset \mathcal{A} \implies [X_i \leq x_i] \subset \mathcal{A}$ , y al revés sabiendo que  $\bigcap_{i=1}^n [X_i \leq x_i] \subset [X_i \leq x_i] \subset \mathcal{A}$ .

**Ejercicio 2.4.** Sean  $X$  e  $Y$  variables aleatorias independientes tales que  $E[X] = 0$ ,  $Var(X) = 1$  y la variable  $Y$  tiene distribución uniforme en  $[-\pi, \pi]$ . Consideremos el proceso estocástico  $\{X_t\}_{t \geq 0}$  definido por

$$X_t = X \cos(t + Y)$$

Calcular las funciones media y covarianza y decir si el proceso es débilmente estacionario.

**Solución.** Primero veamos que efectivamente  $\{X_t\}_{t \geq 0}$  es un proceso estocástico. Para  $t \geq 0$ , tenemos que  $X_t : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B})$ , luego falta ver que es medible, pero funciones Borel de variables aleatorias son medibles y el producto de funciones medibles es medible.

Función media:  $\mu(t) = E[X_t] = E[X \cos(t + Y)]$ , como  $\cos(t + Y)$  es función medible por composición de funciones medibles junto a que  $X$  y  $Y$  son independientes, entonces  $X$  y  $\cos(t + Y)$  son independientes; luego  $E[X \cos(t + Y)] = E[X]E[\cos(t + Y)] = 0$ . Luego  $\mu(t) = 0$ ,  $\forall t \geq 0$ .

Función covarianza:  $C(s, t) = R(s, t) - \mu_t \mu_s = R(s, t) = E[X_t X_s] = E[X^2 \cos(t + Y) \cos(s + Y)]$ , por la independencia otra vez,  $E[X^2 \cos(t + Y) \cos(s + Y)] = E[X^2]E[\cos(t + Y) \cos(s + Y)] = Var(X)E[\cos(t + Y) \cos(s + Y)] = E[\cos(t + Y) \cos(s + Y)]$ , resolvemos la integral  $\frac{1}{2\pi} \int_{-\pi}^{\pi} \cos(t + y) \cos(s + y) dy$  y tenemos que  $C(s, t) = \frac{1}{2} \cos(s - t)$ .

Este pe. es débilmente estacionario ya que su función media es constante,  $\mu(t) = 0$ ,  $\forall t \geq 0$ ; y la función covarianza cumple  $C(s, t) = \frac{1}{2} \cos(s - t) = \frac{1}{2} \cos(s + h - t - h) = C(s + h, t + h) = C(0, t - s)$ ,  $\forall t, s \geq 0$ .

**Ejercicio 2.5.** Ejemplos de procesos estocásticos atendiendo a la clasificación según el espacio de estados y espacio paramétrico.

**Solución.** Ejemplos:

- PDTD: N° de productos fabricados al día  $\equiv X_n$   
 $T \equiv \mathbb{N}(\text{días})$ ,  $E = \mathbb{N} \cup \{0\}$  (n° productos).
- PCTD: Nota media por curso  $\equiv X_n$   
 $T = \{1, 2, 3, 4, 5\}$  (curso),  $E = [0, 10]$  (nota media).
- PDTC: N° de lanzamientos hechos en el instante  $t \equiv X_t$   
 $T = \mathbb{R}_0^+$  (tiempo),  $E = \mathbb{N} \cap \{0\}$  (lanzamientos).
- PCTC: Temperatura en una ciudad en el instant  $t \equiv X_t$   
 $T = \mathbb{R}_0^+$  (tiempo),  $E = \mathbb{R}^+$  (Kelvin).

**Ejercicio 2.6.** Demostrar que si las componentes del vector aleatorio  $X = (X_1, \dots, X_n)^T$  son independientes, entonces la función característica del vector  $X$  es igual al producto de las funciones características de las variables  $X_k$ ,  $k = 1, \dots, n$ .

## 2. Tema 1

**Solución.** Sea un vector aleatorio  $X = (X_1, \dots, X_n)$ , la función característica del vector  $X$  es  $\varphi_X(t) = E[e^{it^T X}] = E[e^{i(t_1 X_1 + \dots + t_n X_n)}] = E[e^{it_1 X_1 + \dots + it_n X_n}] = E[\prod_{k=1}^n e^{it_k X_k}] = \prod_{k=1}^n E[e^{it_k X_k}] = \prod_{k=1}^n \varphi_{X_k}(t_k)$ . Podemos separar las esperanzas ya que  $X_1, \dots, X_n$  son independientes y  $e^{itx}$  es función Borel de variable aleatoria; y por tanto  $e^{itX_k}$ ,  $k = 1, \dots, n$ , siguen siendo independientes.

**Ejercicio 2.7.** Demostrar que para un proceso con incrementos independientes las distribuciones finito dimensionales del proceso (esto es, las distribuciones de los vectores  $(X_{t_1}, X_{t_2}, \dots, X_{t_n})^T$ ,  $\forall t_1 < t_2 < \dots < t_n$ ) están determinadas por las distribuciones marginales unidimensionales  $(X_{t_1})$  y por las distribuciones de los incrementos  $(X_{t_i} - X_{t_{i-1}}, i = 2, \dots, n)$ .

**Solución.** Tenemos un  $\{X_t\}_{t \in T}$  p.e con incrementos independientes, entonces  $\forall t_1 < \dots < t_n \in T$ ,  $X_{t_1}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$  son v.a independientes.

Definimos  $S_1 = X_{t_1}$ ,  $S_2 = X_{t_2} - X_{t_1} \implies X_{t_2} = S_1 + S_2$

$S_3 = X_{t_3} - X_{t_2} \implies X_{t_3} = S_1 + S_2 + S_3$ , por tanto  $X_{t_k} = \sum_{j=1}^k S_j$ .

$\phi_{(X_{t_1}, \dots, X_{t_n})}(u_1, \dots, u_n) = \phi_{(S_1, \dots, S_n)}(v_1, \dots, v_n)$

**Ejercicio 2.8.** Demostrar que la clase de rectángulos medibles  $\mathcal{C}^{\mathbb{N}}$  es una semi-álgebra.

**Solución.** Tenemos que

$$\mathcal{C}^{\mathbb{N}} = \left\{ \prod_{i=1}^{\infty} A_i : n \in \mathbb{N}, A_i \in \mathcal{B}, A_j = \mathbb{R}, 1 \leq i \leq n, j > n \right\}$$

Veamos que  $\mathcal{C}^{\mathbb{N}}$  es una semi-álgebra.

(i)  $\mathbb{R}^{\mathbb{N}} \in \mathcal{C}^{\mathbb{N}}$ .

Como  $\mathbb{R} \in \mathcal{B}$  ( $\mathcal{B}$  es  $\sigma$ -álgebra)  $\implies \mathbb{R}^{\mathbb{N}} \in \mathcal{C}^{\mathbb{N}}$ .

(ii)  $\forall A, B \in \mathcal{C}^{\mathbb{N}} \implies A \cap B \in \mathcal{C}^{\mathbb{N}}$ .

Sean  $A, B \in \mathcal{C}^{\mathbb{N}}$ ,  $A \cap B = (\prod_{n=1}^{\infty} A_n) \cap (\prod_{n=1}^{\infty} B_n) = \prod_{n=1}^{\infty} (A_n \cap B_n) \in \mathcal{C}^{\mathbb{N}}$ , ya que  $A_i, B_i \in \mathcal{B} \implies A_i \cap B_i \in \mathcal{B}$  (por ser  $\mathcal{B}$   $\sigma$ -álgebra).

(iii)  $\forall A, B \in \mathcal{C}^{\mathbb{N}}, \exists \{C_i\}_{i=1}^n \subset \mathcal{C}^{\mathbb{N}}$  disjuntos dos a dos tal que  $A \setminus B = \bigcup_{i=1}^n C_i$ .

Sean  $A, B \in \mathcal{C}^{\mathbb{N}}$ ,  $A \setminus B = (\prod_{n=1}^{\infty} A_n) \setminus (\prod_{n=1}^{\infty} B_n) = \prod_{n=1}^{\infty} (A_n \setminus B_n) = C \in \mathcal{C}^{\mathbb{N}}$ , ya que  $A_i \setminus B_i = A_i \cap \overline{B_i} \in \mathcal{B}$  ( $\mathcal{B}$  es  $\sigma$ -álgebra).

**Ejercicio 2.9.** Demostrar el Teorema de medibilidad para procesos estocásticos en tiempo discreto.

## 2. Tema 1

**Solución.** Sea la función

$$\begin{aligned}\chi : (\Omega, \mathcal{A}) &\rightarrow (\mathbb{R}^{\mathbb{N}}, \mathcal{B}^{\mathbb{N}}) \\ \omega &\mapsto X(\omega) = \{X_n(\omega)\}_{n \in \mathbb{N}}\end{aligned}$$

Entonces  $\chi$  es medible  $\iff \{X_n\}_{n \in \mathbb{N}}$  son medibles.



### 2.2. Ejercicios en clase

**Ejercicio 2.10.** Sea el espacio de probabilidad  $([-1, 1], \mathcal{B}_{[-1,1]}, U[-1, 1])$  y

$$\forall n \in \mathbb{N}, X_n(\omega) = \begin{cases} -1, & \omega \in [-1, \frac{-1}{n}] \\ 0, & \omega \in [\frac{-1}{n}, \frac{1}{n}] \\ 1, & \omega \in [\frac{1}{n}, 1] \end{cases}$$

Y las trayectorias:

$$\begin{aligned}\omega \in [-1, 0) &\rightarrow \chi(\omega) = \begin{cases} 0, & n \leq \frac{-1}{\omega} \\ -1, & n \geq \frac{-1}{\omega} \end{cases} \\ \omega \in [0, 1] &\rightarrow \chi(\omega) = \begin{cases} 0, & n < \frac{1}{\omega} \\ 1, & n \geq \frac{1}{\omega} \end{cases}\end{aligned}$$

**Solución.** Los pasos a seguir son:

- (i) Demostrar que tenemos un PETD (p.e)
- (ii) Obtener las trayectorias
- (iii) Obtener la distribución basandonos en la trayectoria
- (iv) Ver que la distribución queda dada por distribuciones finito dimensionales

Veamos la distribución:

$$\begin{aligned}P[X_1 = 0] &= P((-1, 1)) = 1 \\ P[X_1 = 0, X_2 = 0] &= P((-1, 1) \cap (\frac{-1}{2}, \frac{1}{2})) = P[(\frac{-1}{2}, \frac{1}{2})] = \frac{1}{2} \\ P[X_1 = 0, X_2 = 1] &= P((-1, 1) \cap [-1, \frac{-1}{2}]) = P[(-1, \frac{-1}{2}]] = \frac{1}{4} \\ P[X_1 = 0, X_2 = 2] &= P((-1, 1) \cap (\frac{1}{2}, 1]) = P[(\frac{1}{2}, 1]] = \frac{1}{4} \\ P[X_1 = 0, \dots, X_n = 0] &= P((-1, 1) \cap (\frac{-1}{2}, \frac{1}{2}) \cap \dots \cap (\frac{-1}{n}, \frac{1}{n})) = P((\frac{-1}{n}, \frac{1}{n})) = \frac{1}{n}. \\ P[X_1 = 0, \dots, X_{k-1} = 0, X_k = -1, \dots, X_n = -1] &= P((-1, 1) \cap \dots \cap (\frac{-1}{k-1}, \frac{1}{k-1}) \cap \\ &[-1, \frac{-1}{k}] \cap \dots \cap [-1, \frac{-1}{n}]) = P((\frac{-1}{k-1}, \frac{1}{k-1}) \cap [-1, \frac{-1}{k}]) = \frac{1}{2k(k-1)} \\ P[X_1 = 0, \dots, X_{k-1} = 0, X_k = 1, \dots, X_n = 1] &= P((-1, 1) \cap \dots \cap [\frac{1}{k-1}, 1] \cap \dots \cap \\ &[\frac{1}{n}, 1]) = P((\frac{-1}{k-1}, \frac{1}{k-1}) \cap [\frac{1}{k}, 1]) = \frac{1}{2k(k-1)}\end{aligned}$$

Comprobamos que es una probabilidad (viendo que suma):

$$\frac{1}{n} + \sum_{k=2}^n \frac{1}{2k(k-1)} + \sum_{k=2}^n \frac{1}{2k(k-1)} = \frac{1}{n} + \sum_{k=2}^n \frac{1}{k(k-1)}, \quad k = 2, 3, \dots, n$$

Por ejemplo por  $n = 3, 4$ :

$$n = 3 \rightarrow \frac{1}{3} + \frac{1}{2} + \frac{1}{6} = 1.$$

$$n = 4 \rightarrow \frac{1}{4} + \frac{1}{2} + \frac{1}{6} + \frac{1}{12} = 1.$$

### 2.3. Ejercicios PETC

**Ejercicio 2.11.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio probabilístico, con  $\Omega = [0, 1]$ ,  $\mathcal{A} = \mathcal{B}_{[0,1]}$ , y  $P$  la distribución uniforme en  $[0, 1]$ . Definimos  $\{X_n\}_{n \geq 4}$  sobre  $(\Omega, \mathcal{A}, P)$  por

$$\forall n \geq 4, X_n(\omega) = \begin{cases} 0, & \text{si } 0 \leq \omega < \frac{1}{4} - \frac{1}{n} \\ 1, & \text{si } \frac{1}{4} - \frac{1}{n} \leq \omega < \frac{1}{2} - \frac{1}{n} \\ 2, & \text{si } \frac{1}{2} - \frac{1}{n} \leq \omega < \frac{3}{4} - \frac{1}{n} \\ 3, & \text{si } \frac{3}{4} - \frac{1}{n} \leq \omega \leq 1 \end{cases}$$

Demostrar que  $\{X_n\}_{n \geq 4}$  es un proceso estocástico, calcular sus trayectorias y su distribución.

*Solución.* Veamos primero que es un proceso estocástico (las  $X_n$  son medibles):

Como  $X_n = 1_{[\frac{1}{4}-\frac{1}{n}, \frac{1}{2}-\frac{1}{n}]} + 2_{[\frac{1}{2}-\frac{1}{n}, \frac{3}{4}-\frac{1}{n}]} + 3_{[\frac{3}{4}-\frac{1}{n}, 1]}$ , es decir, es suma de funciones indicadoras de conjuntos medibles, por tanto medibles.

Definimos las trayectorias:

$$\begin{aligned} \chi : \Omega &\rightarrow \mathbb{R}^{\mathbb{N}} \\ \omega &\mapsto \{X_n(\omega)\}_{n \geq 4} \end{aligned}$$

Tenemos que:

- $\chi(0) = \{0, 0, \dots, 0, \dots\}$
- $\chi(\frac{1}{4}) = \{1, 1, \dots, 1, \dots\}$
- $\chi(\frac{1}{2}) = \{2, 2, \dots, 2, \dots\}$
- $\omega \in [\frac{3}{4}, 1] \implies \chi(\omega) = \{3\}_{n \geq 4}$
- $\omega \in (0, \frac{1}{4}) = (0, \frac{1}{4} - \frac{1}{n}) \cup [\frac{1}{4} - \frac{1}{n}, \frac{1}{4}]$

$$\begin{aligned} - \omega < \frac{1}{4} - \frac{1}{n} &\iff \frac{1}{n} < \frac{1}{4} - \omega \iff n > \frac{4}{1-4\omega} \implies X_n(\omega) = 0 \\ - \omega \geq \frac{1}{4} - \frac{1}{n} &\iff n \leq \frac{4}{1-4\omega} \implies X_n(\omega) = 1 \end{aligned}$$

Por tanto

- $\omega \in (\frac{1}{4}, \frac{1}{2}) = (\frac{1}{4}, \frac{1}{2} - \frac{1}{n}) \cup [\frac{1}{2} - \frac{1}{n}, \frac{1}{2})$
- $\omega < \frac{1}{2} - \frac{1}{n} \iff n > \frac{2}{1-2\omega} \implies X_n(\omega) = 1$



## 2. Tema 1

$$- \omega \geq \frac{1}{2} - \frac{1}{n} \iff n \geq \frac{2}{1-2\omega} \implies X_n(\omega) = 2$$

Por tanto  $\forall \omega \in (\frac{1}{4}, \frac{1}{2})$ ,  $\chi(\omega) =$

Ahora obtendremos la distribución, que está determinada por las distribuciones finito dimensionales:

- $P[X_5 = 0, X_6 = 0, \dots, X_n = 0] = P[(0, \frac{1}{4} - \frac{1}{5} \cap \dots \cap (0, \frac{1}{4} - \frac{1}{n})] = P[(0, \frac{1}{4} - \frac{1}{5})] = \frac{1}{4} - \frac{1}{5} = \frac{1}{20}$
- $P[X_5 = 1, X_6 = 1, \dots, X_n = 1] = P[(\frac{1}{4} - \frac{1}{5}, \frac{1}{2} - \frac{1}{5}) \cap \dots \cap (\frac{1}{4} - \frac{1}{n}, \frac{1}{2} - \frac{1}{n})] = P[(\frac{1}{4} - \frac{1}{n}, \frac{1}{2} - \frac{1}{5})] = \frac{1}{n} + \frac{1}{20}$
- $P[X_5 = 2, \dots, X_n = 2] = P[C_5 \cap \dots \cap C_n] = P[(\frac{1}{2} - \frac{1}{n}, \frac{3}{4} - \frac{1}{5})] = \frac{1}{20} + \frac{1}{n}$
- $P[X_5 = 3, \dots, X_n = 3] = P[D_5 \cap \dots \cap D_n] = P[(\frac{3}{4} - \frac{1}{n}, 1)] = \frac{1}{4} + \frac{1}{n}$
- $P[X_5 = 1, X_6 = 1, \dots, X_{k-1} = 1, X_k = 0, \dots, X_n = 0] = P[B_5 \cap B_6 \cap \dots \cap B_{k-1} \cap A_k \cap \dots \cap A_n] = P[(\frac{1}{4} - \frac{1}{k-1}, \frac{1}{4} - \frac{1}{k})] = \frac{1}{(k-1)k}$
- $P[X_5 = 2, X_6 = 2, \dots, X_{k-1} = 2, X_k = 1, \dots, X_n = 1] = P[C_5 \cap \dots \cap C_{k-1} \cap B_k \cap \dots \cap B_n] = P[(\frac{1}{2} - \frac{1}{k-1}, \frac{3}{4} - \frac{1}{5}) \cap (\frac{1}{4} - \frac{1}{n}, \frac{1}{2} - \frac{1}{k})] = P[(\frac{1}{2} - \frac{1}{k-1}, \frac{1}{2} - \frac{1}{k})] = \frac{1}{(k-1)k}$
- $P[X_5 = 3, \dots, X_{k-1} = 3, X_k = 2, \dots, X_n = 2] = P[D_5 \cap \dots \cap D_{k-1} \cap C_k \cap \dots \cap C_n] = P[(\frac{3}{4} - \frac{1}{k-1}, \frac{3}{4} - \frac{1}{k})] = \frac{1}{(k-1)k}$

Comprobamos que las probabilidades suman uno:

$$\begin{aligned} \frac{1}{20} + (\frac{1}{n} + \frac{1}{2}) + (\frac{1}{n} + \frac{1}{20}) + (\frac{1}{n} + \frac{1}{20}) + (\frac{1}{4} + \frac{1}{n}) + 3 \sum_{k=6}^n \frac{1}{(k-1)k} = \\ = \frac{3}{n} + \frac{2}{5} + 3 \sum_{k=6}^n \frac{1}{(k-1)k}, \quad n > 4 \end{aligned}$$

Tomamos valores de  $n$  y lo comprobamos fácilmente, por ej  $n = 5, 6, \dots, 10, 50$ .